
RELAZIONE DI LABORATORIO
COMPUTAZIONALE

Isabella Inuso
561434

Confronto tra
Complessi Simpliciali

Anno
Accademico
2024/25

Indice

1	Introduzione	1
2	Basi di Topologia Algebrica	1
2.1	Complessi Simpliciali	1
2.2	Omologia	2
2.3	Mappe indotte su gruppi di omologia	4
3	Omologia Persistente e Algoritmo di Calcolo	5
3.1	Omologia Persistente	5
3.2	Barcode	6
3.3	Algoritmo di Calcolo dell'Omologia Persistente	6
3.4	Diagrammi di Persistenza e Distanza Bottleneck	8
4	Complessi Simpliciali Filtrati	9
5	Sperimentazione	13
5.1	Estrazione dei Campioni	13
5.2	Generazione dei Complessi	14
5.3	Analisi delle Prestazioni	15
5.4	Confronti	16
5.5	Analisi della Convergenza	17

1 Introduzione

L'analisi topologica dei dati è un campo in rapida crescita che si occupa di studiare le proprietà topologiche dei dati attraverso strumenti matematici. In questo contesto, i complessi simpliciali sono strutture fondamentali che permettono di rappresentare e analizzare la forma dei dati in modo efficace. Questa relazione si propone di confrontare diversi tipi di complessi simpliciali, come i complessi di Vietoris-Rips, i complessi di Čech, i complessi alpha e i complessi witness, comparando le omologie persistenti ottenute a partire dagli stessi dati passando attraverso i vari complessi.

2 Basi di Topologia Algebrica

Supponiamo di avere a disposizione dati che si trovano in uno spazio metrico, come ad esempio un sottoinsieme dello spazio euclideo dotato della distanza indotta. In molte situazioni, non siamo interessati alla geometria precisa di questi spazi, ma cerchiamo piuttosto di comprendere alcune caratteristiche fondamentali, come il numero di componenti connesse o l'esistenza di buchi e cavità. La topologia algebrica cattura queste caratteristiche di base contandole oppure associando ad esse spazi vettoriali o strutture algebriche più sofisticate. In questo contesto, ci interessiamo all'omologia, che associa uno spazio vettoriale $H_i(X)$ a uno spazio X per ogni numero naturale $i \in \{0, 1, 2, \dots\}$. La dimensione di $H_0(X)$ conta il numero di componenti connesse di X , la dimensione di $H_1(X)$ rappresenta il numero di buchi, e la dimensione di $H_2(X)$ conta il numero di cavità. Una proprietà importante di queste strutture algebriche è la loro robustezza, poiché non cambiano quando lo spazio sottostante viene trasformato mediante piegature, stiramenti o altre deformazioni. In termini tecnici, sono invarianti omotopiche.

Il calcolo dell'omologia di spazi topologici arbitrari può risultare molto difficile. Pertanto, approssimiamo i nostri spazi mediante strutture combinatoriali chiamate "complessi simpliciali", per i quali l'omologia può essere calcolata facilmente mediante algoritmi. Spesso, infatti, non disponiamo nemmeno dello spazio X , ma possediamo soltanto un insieme campione discreto S dal quale costruire un complesso simpliciale seguendo una delle procedure descritte nelle sezioni successive.

2.1 Complessi Simpliciali

Cominciamo con una breve introduzione ai complessi simpliciali e alle mappe tra di essi. Intuitivamente, un complesso simpliciale è un'unione di punti,

linee, triangoli, tetraedri, e politopi in dimensioni superiori. Vediamo una definizione rigorosa.

Definizione 2.1. Sia K_0 un insieme. Un **complesso simpliciale astratto** su K_0 è una collezione K di sottoinsiemi non vuoti di K_0 tale che:

- per ogni $v \in K_0$, $\{v\} \in K$;
- Se $\sigma \in K$ e $\tau \subseteq \sigma$, allora $\tau \in K$.

Gli elementi di K_0 sono detti **vertici** del complesso simpliciale K , mentre gli elementi di K sono detti **simplessi** di K .

Sia $\sigma \in K$ un semplice. Se $|\sigma| = p+1$, allora diciamo che σ ha **dimensione** p e lo chiamiamo **p -simple**. Denotiamo con K_p l'insieme di tutti i p -simplessi di K . La **dimensione** del complesso simpliciale K è definita come la massima dimensione dei suoi simplessi. Il **k -scheletro** di K è il sottocomplesso formato da tutti i simplessi di dimensione minore o uguale a k , ovvero l'unione dei K_p per $p = 0, \dots, k$. Ogni semplice $\tau \subset \sigma$ è detto **faccia** di σ , e diciamo che τ è una faccia di σ di **codimensione** q se la sua dimensione differisce di q da quella di σ . Diciamo che $L \subseteq K$ è un **sottocomplesso** di K se, per ogni $\sigma \in L$, ogni faccia di σ in K appartiene a L .

Osservazione 2.1. È possibile associare a ogni complesso simpliciale astratto una *realizzazione geometrica*. Questa consiste in un sottoinsieme di $\mathbb{R}^n$ (per un opportuno n) formato da punti e da involucri convessi di tali punti, i quali rappresentano rispettivamente i vertici e i simplessi del complesso simpliciale.

Sia K un complesso simpliciale astratto.

Definizione 2.2. Dati K e L due complessi simpliciali rispettivamente su K_0 e L_0 , una **mappa simpliciale** $f : K \rightarrow L$ è una mappa $f : K_0 \rightarrow L_0$ tale che per ogni semplice $\sigma = \{v_1, \dots, v_n\}$ in K , $f(\sigma) = \{f(v_1), \dots, f(v_n)\}$ è un semplice di L .

Chiamiamo f un **isomorfismo** se esiste un'inversa $g : L \rightarrow K$ tale che $f \circ g = \text{id}_L$ e $g \circ f = \text{id}_K$.

2.2 Omologia

Introduciamo ora i concetti di catene e gruppi di omologia, che ci permettono di associare a un complesso simpliciale un insieme di spazi vettoriali, chiamati gruppi di omologia, che catturano le proprietà topologiche del complesso.

Possiamo definire un' **orientazione** su K come una funzione $o : K_0 \rightarrow \mathbb{N}$, che associa un ordine ai vertici del complesso simpliciale. Questo ci permette

di scrivere i semplici come tuple ordinate, cioè come $(v_0, \dots, v_k)$, dove v_i sono i vertici del semplice e $o(v_i) < o(v_j)$ se $i < j$.

Dato un semplice $\sigma = (v_0, \dots, v_k)$, possiamo quindi definire la **faccia i -esima** di σ come il $(k-1)$ -simpleso ottenuto rimuovendo il vertice v_i , cioè $\sigma_{-i} = (v_0, \dots, \widehat{v_i}, \dots, v_k)$.

Sia K un complesso simpliciale orientato, e sia $\mathbb{F}$ un campo.

Definizione 2.3. Sia $p \geq 0$. Il p -esimo **gruppo delle catene** di K su $\mathbb{F}$ è lo spazio vettoriale $\mathcal{C}_p(K, \mathbb{F})$ su $\mathbb{F}$ che ha come base i p -semplici di K .

Chiamiamo $\gamma \in \mathcal{C}_p(K, \mathbb{F})$ una **p -catena** di K , e possiamo scriverla come

$$\gamma = \sum_{\sigma \in K_p} c_\sigma \sigma, \quad \text{con } c_\sigma \in \mathbb{F}.$$

Definiamo il p -esimo **operatore di bordo** di K come la mappa $\mathbb{F}$ -lineare $\partial_p : \mathcal{C}_p(K, \mathbb{F}) \rightarrow \mathcal{C}_{p-1}(K, \mathbb{F})$ per cui, per ogni σ nella base di $\mathcal{C}_p(K, \mathbb{F})$, vale che

$$\partial_p(\sigma) = \sum_{i=0}^p (-1)^i \sigma_{-i}$$

dove assumiamo che $\mathcal{C}_{-1}(K, \mathbb{F}) = \{0\}$.

Quindi, per ogni p , la mappa ∂_p associa a ogni p -catena γ il suo **bordo**, cioè la somma delle sue facce di dimensione $p-1$.

In seguito, per brevità, indicheremo con $\mathcal{C}_p(K)$ il gruppo delle catene per un generico campo $\mathbb{F}$.

Proposizione 2.2. Per ogni $p \geq 0$, vale che $\partial_p \circ \partial_{p+1} = 0$.

Pertanto, l'immagine di ∂_{p+1} è contenuta nel nucleo di ∂_p , è quindi ben definito il quoziente della seguente Definizione:

Definizione 2.4. Per ogni $p \geq 0$, il p -esimo **gruppo di omologia** di K è definito come il quoziente:

$$H_p(K) = \text{Ker}(\partial_p) / \text{Im}(\partial_{p+1})$$

Chiamiamo **p -cicli** gli elementi di $\text{Ker}(\partial_p)$, e **p -bordi** gli elementi di $\text{Im}(\partial_{p+1})$. Chiamiamo inoltre **p -esimo numero di Betti** di K la sua dimensione:

$$\beta_p(K) = \dim H_p(K) = \dim \text{Ker}(\partial_p) - \dim \text{Im}(\partial_{p+1}).$$

Intuitivamente, i p -cicli che non sono bordi rappresentano “buchi” di dimensione p . Perciò i numeri di Betti “contano” il numero di buchi. Inoltre, $H_p(K) = 0$ per ogni p maggiore di n , con n la dimensione di K , e di conseguenza anche $\mathcal{C}_p(K) = 0$.

Otteniamo quindi una successione di spazi vettoriali della forma:

$$0 \xrightarrow{\partial_{n+1}} \mathcal{C}_n(K) \xrightarrow{\partial_n} \cdots \xrightarrow{\partial_1} \mathcal{C}_0(K) \xrightarrow{\partial_0} 0.$$

2.3 Mappe indotte su gruppi di omologia

Vediamo ora che una mappa tra complessi simpliciali induce una mappa in omologia compatibile con la composizione, proprietà nota come “functorialità”. Dati K, K' due complessi simpliciali e $f : K \rightarrow K'$ una mappa simpliciale, questa induce, per ogni $p \geq 0$, una mappa $\mathbb{F}$ -lineare $\tilde{f}_p : \mathcal{C}_p(K) \rightarrow \mathcal{C}_p(K')$, definita sui σ nella base di $\mathcal{C}_p(K)$ come:

$$\tilde{f}_p(\sigma) = \begin{cases} f(\sigma) & \text{se } \dim f(\sigma) = p, \\ 0 & \text{altrimenti.} \end{cases}$$

Proposizione 2.3. *Sia $f : K \rightarrow K'$ una mappa simpliciale tra complessi simpliciali. Allora, per ogni $p \geq 0$ e $\sigma \in K_p$, vale che:*

$$\tilde{f}_{p-1} \circ \partial_p(\sigma) = \partial'_p \circ \tilde{f}_p(\sigma),$$

con ∂_p^K e $\partial_p^{K'}$ gli operatori di bordo di K e K' , rispettivamente.

Osservazione 2.4. Abbiamo inoltre che le mappe $\tilde{f}_p$ mandano bordi in bordi e cicli in cicli, cioè

$$\tilde{f}_p(\text{Ker}(\partial_p)) \subseteq \text{Ker}(\partial'_p), \quad \tilde{f}_p(\text{Im}(\partial_{p+1})) \subseteq \text{Im}(\partial'_{p+1})$$

Questo ci permette di dire che la seguente definizione è ben posta:

Definizione 2.5. Sia K e K' due complessi simpliciali, e sia $f : K \rightarrow K'$ una mappa simpliciale. Per ogni $p \geq 0$, definiamo la mappa $f_p : H_p(K) \rightarrow H_p(K')$ indotta da f sui gruppi di omologia come:

$$f_p([\gamma]) = [\tilde{f}_p(\gamma)]$$

per ogni $[\gamma] \in H_p(K)$, dove $[\gamma]$ denota la classe di equivalenza di $\gamma \in \mathcal{C}_p(K)$ in $H_p(K)$.

Proposizione 2.5. *Sia K, L, M tre complessi simpliciali, e siano $f : K \rightarrow L$ e $g : L \rightarrow M$ due mappe simpliciali. Allora, per ogni $k \geq 0$, vale che:*

$$(g \circ f)_p = g_p \circ f_p.$$

3 Omologia Persistente e Algoritmo di Calcolo

Supponiamo di avere a disposizione dati sperimentali sotto forma di uno spazio metrico finito S , costituito da un insieme di punti o vettori che rappresentano misurazioni e da una funzione di distanza sull'insieme. Possiamo pensare l'insieme S come un campionamento di uno spazio topologico. Il nostro obiettivo è recuperare le proprietà di tale spazio in modo robusto rispetto a piccole perturbazioni nei dati S .

3.1 Omologia Persistente

Partendo da un insieme di dati S , è possibile costruire una famiglia di complessi simpliciali parametrizzata da un valore ε , dove all'aumentare di questo parametro vengono aggiunti progressivamente nuovi simplessi ai complessi. Si può quindi tentare di calcolare le caratteristiche qualitative dell'insieme di dati S calcolando l'omologia simpliciale del complesso relativo a ε . Il problema di questo approccio è che non esiste a priori una scelta chiara per il valore del parametro ε .

L'intuizione chiave dell'omologia persistente è la seguente: per estrarre informazioni qualitative dai dati, si considerano diversi (o anche tutti i) possibili valori del parametro ε . L'omologia persistente cattura quindi come l'omologia dei complessi cambia al variare del valore del parametro, e rileva quali caratteristiche topologiche “persistono”.

Definizione 3.1. Sia K un complesso simpliciale finito. Una **filtrazione** di K (di lunghezza n) è una famiglia di sottocomplessi $K_{i \in I}$, con $I = \{1, \dots, n\}$ un insieme finito di indici, tale che:

- $K_i \subseteq K_j$ se $i \leq j$;
- $\bigcup_{i \in I} K_i = K$.

Consideriamo ora un complesso simpliciale K e una filtrazione $K_1 \subseteq \dots \subseteq K_n$ di K . Per ogni $p \geq 0$, possiamo considerare le inclusioni $K_i \rightarrow K_j$ per ogni $i \leq j$; queste sono mappe simpliciali, e quindi inducono delle mappe lineari in omologia

$$f_{i,j} : H_p(K_i) \rightarrow H_p(K_j).$$

Inoltre, per la Proposizione 2.5, vale

$$f_{k,j} \circ f_{i,k} = f_{i,j} \text{ per ogni } i \leq k \leq j.$$

Possiamo quindi dare la definizione centrale di questa relazione.

Definizione 3.2. Siano $K_1 \subseteq \dots \subseteq K_n$ un complesso simpliciale filtrato e, per ogni $i \leq j$, $f_{i,j} : H_p(K_i) \rightarrow H_p(K_j)$ le mappe indotte dalle inclusioni come sopra. Chiamiamo **p -esima omologia persistente** di K la coppia

$$(\{H_p(K_i)\}_{1 \leq i \leq n}, \{f_{i,j}\}_{1 \leq i \leq j \leq n})$$

Diciamo che $x \in H_p(K_i)$ **nasce** in $H_p(K_i)$ se non appartiene a $\text{Im}(f_{i-1,i})$, mentre diciamo che x **muore** in $H_p(K_j)$ se $j > i$ è il più piccolo indice tale che $f_{i,j}(x) = 0$, nel caso in cui non esista un tale j , poniamo l'indice della morte di x uguale a $+\infty$ e diciamo che x **vive per sempre**. Chiamiamo **intervallo di vita** di x l'intervallo aperto $[i, j)$.

3.2 Barcode

Possiamo rappresentare le informazioni fornite dalla p -esima omologia persistente di un complesso K attraverso ciò che chiamiamo **barcode**, che è un diagramma costruito come segue:

- Per ogni $i \in \{1, \dots, n\}$, disegniamo un numero di punti corrispondente alla dimensione di $H_p(K_i)$;
- Se il generatore di $H_p(K_i)$ corrispondente al punto u è mandato nel generatore di $H_p(K_{i+1})$ corrispondente al punto v , disegniamo una linea orizzontale che li collega;
- Se il generatore di $H_p(K_i)$ corrispondente al punto u muore in $H_p(K_{i+1})$, cioè è mandato in 0 da $f_{i,i+1}$, disegniamo una linea orizzontale che parte da u e termina alla filtrazione $i + 1$.

Osservazione 3.1. Il barcode dipende dalla scelta delle basi degli spazi di omologia, tuttavia per il *Teorema di Struttura*[4] dell'omologia persistente, esiste una base per ogni $H_p(K_i)$ tale che il diagramma sia una collezione ben definita e unica di intervalli semi-aperti disgiunti.

3.3 Algoritmo di Calcolo dell'Omologia Persistente

Al fine di calcolare l'omologia persistente di un complesso simpliciale filtrato K , utilizziamo una *matrice di incidenza*, che è una rappresentazione delle relazioni tra i semplici di K e le loro facce.

Sia $K_1 \subseteq \dots \subseteq K_n = K$ un complesso simpliciale filtrato. Ordiniamo i semplici di K compatibilmente con la filtrazione:

- Se τ è una faccia di σ , allora $\tau < \sigma$
- Se $i < j$, allora $\forall \tau \in K_i, \sigma \in K_j \setminus K_i$, vale $\tau < \sigma$.

Definizione 3.3. Dati $\sigma_1, \dots, \sigma_N$ i semplici di K ordinati come descritto sopra, la **matrice di incidenza** di K è la matrice $M = (\delta_{i,j})_{i,j \in \{1, \dots, N\}}$ tale che

$$\delta_{i,j} = \begin{cases} 1 & \text{se } \sigma_i \text{ è una faccia di codimensione 1 di } \sigma_j, \\ 0 & \text{altrimenti} \end{cases}$$

Per passare da una matrice di incidenza M alla matrice che rappresenta effettivamente il barcode dell'omologia persistente di K , dobbiamo ridurre M tramite eliminazione gaussiana. Noi vedremo solo l'*algoritmo standard* di riduzione.

Definiamo la funzione **pivot** come la funzione $\text{low} : \{1, \dots, n\} \rightarrow \{0, 1, \dots, n\}$ con $\text{low}(j)$ il massimo i tale che $\delta_{i,j} \neq 0$, cioè l'indice della riga “più bassa” che non è zero nella colonna j della matrice M . Se j ha solo zeri, allora $\text{low}(j) = 0$.

Diciamo che la matrice di incidenza è **ridotta** se low è iniettiva sulle colonne diverse da 0.

L'algoritmo standard è illustrato nel seguente:

Algoritmo 1 Algoritmo standard di riduzione di una matrice di incidenza

```

for  $j = 1, \dots, n$  do
  while  $\exists i < j : \text{low}(i) = \text{low}(j)$  do
    somma la colonna  $i$  alla colonna  $j$ 
  end while
end for

```

Una volta ridotta la matrice, possiamo estrarre il barcode dell'omologia persistente di K analizzando le righe della matrice ridotta. Ogni colonna corrisponde a un generatore di omologia, e le righe non nulle indicano le relazioni di morte tra i generatori. In particolare, accoppiamo i semplici nel seguente modo:

- Se $\text{low}(j) = i \neq 0$, allora accoppiamo σ_i con σ_j , e la caratteristica omologica che nasce quando compare σ_i nella filtrazione muore con l'entrata di σ_j .

- Se $\text{low}(j) = 0$, allora quando σ_j compare nella filtrazione, si crea una nuova caratteristica. Tale caratteristica muore con σ_k se $\text{low}(k) = j$, e in questo caso accoppiamo σ_j con σ_k ; altrimenti σ_j rimane disaccoppiato e la caratteristica corrispondente vive per sempre.

Dato un semplice σ , chiamiamo **grado** di σ , $dg(\sigma)$, il più piccolo numero l tale che $\sigma \in K_l$.

Abbiamo quindi che una coppia (σ_i, σ_j) di semplici corrisponde all'intervallo $[dg(\sigma_i), dg(\sigma_j))$ nel barcode, e un semplice σ_k disaccoppiato corrisponde all'intervallo $[dg(\sigma_k), \infty)$.

3.4 Diagrammi di Persistenza e Distanza Bottleneck

Nelle sperimentazioni è spesso necessario confrontare i barcode ottenuti da diversi complessi simpliciali o da diversi dati. A tale scopo, introduciamo i concetti di *diagramma di persistenza*, che costituisce una rappresentazione alternativa e perfettamente equivalente del barcode, e di *distanza bottleneck*.

Definizione 3.4. Chiamiamo **diagramma di persistenza** un multiinsieme finito di punti nel piano esteso $\mathbb{R} \times (\mathbb{R} \cup \{\infty\})$, dove ogni punto rappresenta un generatore di omologia persistente. L'asse orizzontale rappresenta l'indice di nascita del generatore, mentre l'asse verticale rappresenta l'indice di morte. Includiamo nel diagramma anche tutti i punti sulla diagonale $\Delta = \{(x, x) \mid x \in \mathbb{R}\}$, ognuno con molteplicità infinita.

Consideriamo due diagrammi di persistenza X e Y .

Definizione 3.5. Sia $p \in [1, \infty]$ e d una metrica su $\mathbb{R}^2$. La **p -esima distanza di Wasserstein** tra X e Y è data da

$$W_p[d](X, Y) = \inf_{\substack{\Phi: X \rightarrow Y \\ \Phi \text{ bigezione}}} \left[\sum_{x \in X} d[x, \Phi(x)]^p \right]^{1/p}$$

per $p < \infty$, e

$$W_\infty[d](X, Y) = \inf_{\substack{\Phi: X \rightarrow Y \\ \Phi \text{ bigezione}}} \sup_{x \in X} d[x, \Phi(x)]$$

Chiamiamo **distanza bottleneck** la distanza di Wasserstein $W_\infty[L_\infty]$.

Osservazione 3.2. Il *Primo Teorema di Stabilità*[1] per l'omologia persistente stabilisce che, sotto condizioni favorevoli, il passaggio dai complessi simpliciali filtrati ai barcode è 1-Lipschitz continuo rispetto a opportune funzioni di distanza sui complessi filtrati e alla distanza bottleneck sui barcode. Questo

risultato fondamentale garantisce che piccole variazioni nei dati originali producano solo piccole variazioni nelle strutture topologiche rilevate, rendendo l'omologia persistente robusta al rumore sperimentale.

4 Complessi Simpliciali Filtrati

Come accennato nella Sezione 2, per studiare l'omologia persistente di uno spazio arbitrario vogliamo trovare un complesso simpliciale la cui omologia approssimi abbastanza quella dello spazio. In questa sezione introduciamo delle costruzioni dei complessi che vedremo nelle sperimentazioni, partendo da due costruzioni generiche.

Definizione 4.1. Sia $\mathcal{U} = \{\mathcal{U}_i\}_{i \in I}$ una collezione non vuota di insiemi. Chiamiamo **nervo** di $\mathcal{U}$ il complesso simpliciale i cui vertici sono gli elementi di I e i cui k -simplessi sono le collezioni di $k + 1$ indici $i_0, \dots, i_k$ tali che $\mathcal{U}_{i_0} \cap \dots \cap \mathcal{U}_{i_k} \neq \emptyset$.

Nel caso in cui $\mathcal{U}$ sia un ricoprimento finito composto da insiemi chiusi e convessi di uno spazio euclideo X , il *Teorema del Nervo*[2] ci garantisce che, il nervo di $\mathcal{U}$ è omotopicamente equivalente a X .

Consideriamo ora (X, d) uno spazio metrico ed S un suo sottoinsieme. In ambito applicativo, S rappresenta tipicamente l'insieme delle misurazioni, e si suppone che sia contenuto in uno spazio metrico X di cui non si conosce la struttura globale.

Complesso di Čech

Definizione 4.2. Per ogni $\varepsilon > 0$, sia $S_\varepsilon = \bigcup_{s \in S} B_\varepsilon(s)$, dove $B_\varepsilon(s)$ è la palla aperta di raggio ε centrata in s . Il **complesso di Čech** $\check{C}_\varepsilon(S)$ al parametro ε associato a S è il nervo del ricoprimento $\{S_\varepsilon\}_{\varepsilon > 0}$.

Osservazione 4.1. Nel caso in cui X sia uno spazio euclideo, il Teorema del Nervo ci assicura che il complesso di Čech mantenga l'omologia di S .

Osservazione 4.2. $\check{C}_\varepsilon(S)$ è molto costoso dal punto di vista computazionale, in quanto bisogna considerare un numero molto alto di intersezioni. Inoltre, il complesso può avere dimensione fino a $|\mathcal{U}| - 1$, quindi può avere simplessi di dimensione più grande di quella dello spazio che vorremmo approssimare.




Figura 1: Esempio di un complesso di Čech, con gli 0-simplessi (punti) in $\check{C}_0$, gli 1-simplessi (archi) che si aggiungono in $\check{C}_1$, e un 2-simplesso (triangolo) in $\check{C}_2$.

Complesso di Vietoris-Rips

Definizione 4.3. Dato un insieme $S \subseteq X$, il **complesso di Vietoris-Rips** $VR_\epsilon(S)$ al parametro $\epsilon > 0$ associato a S è il complesso simpliciale i cui vertici sono gli elementi di S e i cui k -simplessi sono le collezioni $\{x_0, \dots, x_k\} \subseteq S$ tali che per ogni coppia di vertici $x_i, x_j \in \{x_0, \dots, x_k\}$, abbiamo $d(x_i, x_j) \leq \epsilon$.

Osservazione 4.3. Nel caso in cui X sia uno spazio euclideo, possiamo dire che il complesso VR approssima il complesso di Čech, nel senso che vale $\check{C}_\epsilon(S) \subseteq VR_\epsilon(S) \subseteq \check{C}_{2\epsilon}(S)$




Figura 2: Il complesso di Čech $\check{C}_\epsilon$ (sinistra) e il complesso di Vietoris-Rips $VR_{2\epsilon}$ (destra) di una nuvola di punti finita nel piano $\mathbb{R}^2$. La parte inferiore di $\check{C}_\epsilon$ è l'unione di due triangoli adiacenti, mentre la parte inferiore di $VR_{2\epsilon}$ è un tetraedro.

Consideriamo lo spazio metrico $X = \mathbb{R}^d$.

Definizione 4.4 (Decomposizione di **Voronoi**). La **decomposizione di Voronoi** di X rispetto ad S è il ricoprimento dato dai

$$V_s = \{x \in \mathbb{R}^d : d(x, s) \leq d(x, s') \text{ per ogni } s' \in S\}$$




Figura 3: Un esempio di decomposizione di Voronoi nel piano

Complesso di Delaunay

Definizione 4.5. Chiamiamo **complesso di Delaunay** $Del(S)$ di S il nervo del ricoprimento dato dalla decomposizione di Voronoi $\{V_s\}_{s \in S}$.

Osservazione 4.4. Nel caso in cui i punti di S siano in posizione generale, il complesso di Delaunay di S ha una realizzazione geometrica che consiste nell'involuppo convesso di S . In questo caso, il complesso è anche chiamato **triangolazione di Delaunay**.




Figura 4: Esempio di triangolazione di Delaunay con decomposizione di Voronoi

Complesso Alpha

Definizione 4.6 (Complesso **Alpha**). Sia $\varepsilon > 0$, e sia $S_\varepsilon = \bigcup_{s \in S} B(s, \varepsilon)$. Il **complesso alpha** $A_\varepsilon(S)$ di S al parametro ε è il nervo del ricoprimento dato da $\{V_s \cap B(s, \varepsilon)\}_{s \in S}$.




Figura 5: Esempio di complesso Alpha con decomposizione di Voronoi

Osservazione 4.5. Notiamo che in generale il complesso alpha è un sottocomplesso del complesso di Delaunay, in particolare $A_\infty(S)$ è proprio il complesso di Delaunay di S . Inoltre, $A_\varepsilon(S)$ è molto simile al complesso di Čech, ma, se i punti di S sono in posizione generale, la dimensione massima dei suoi semplici è minore o uguale a quella dello spazio.

Complessi Witness

Nel caso di dataset molto grandi, la costruzione dei complessi può diventare computazionalmente costosa. Perciò una classe di complessi molto utile è quella dei *complessi witness*.

Prendiamo (S, d) uno spazio metrico, i cui punti chiameremo **witness**, e $L \subseteq S$ un suo sottoinsieme, che chiameremo insieme dei **landmark**.

Definizione 4.7 (Complesso **Witness Debole**). Diciamo che $s \in S$ è un **witness debole** per $\sigma \subseteq L$ se per ogni $x \in \sigma$, e per ogni $y \in L \setminus \sigma$ vale $d(s, x) \leq d(s, y)$. Il **complesso witness debole** $W(S, L)$ di S rispetto a L ha come vertici i punti di L e come semplici i σ che hanno un witness debole in S .

Definizione 4.8 (Complesso **Witness Forte**). Diciamo invece che $s \in S$ è un **witness forte** per $\sigma \subseteq L$ se per ogni $x \in \sigma$, e per ogni $y \in L$ vale $d(s, x) \leq d(s, y)$. E definiamo il **complesso witness forte** $W^+(S, L)$ di S

rispetto a L allo stesso modo del complesso witness debole, ma considerando i witness forti.

Possiamo estendere le definizioni di witness a quelle di α -*witness* per ottenere complessi annidati.

Definizione 4.9 (Complessi Witness **Rilassati**). Diciamo che $s \in S$ è un α -**witness debole** (rispettivamente **forte**) per $\sigma \subseteq L$ se per ogni $x \in \sigma$, e per ogni $y \in L \setminus \sigma$ (rispettivamente $y \in L$) vale $d(s, x)^2 \leq d(s, y)^2 + \alpha^2$. Definiamo il **complesso witness rilassato debole (forte)** $W_\alpha^{(+)}(S, L)$ di S rispetto a L come il complesso che ha come vertici gli elementi di L e come semplici i σ che hanno un α -witness debole (forte) in S .

Osservazione 4.6. Per $\alpha = 0$ abbiamo che $W_0(S, L)$ coincide con il complesso witness debole $W(S, L)$; invece, il complesso forte $W_0^+(S, L)$ consiste di soli punti. Perciò, per α piccoli conviene utilizzare il complesso debole. Spesso però bisogna utilizzare α grandi per calcolare l'omologia, in tal caso è meglio utilizzare il complesso forte, che è più veloce computazionalmente.

5 Sperimentazione

In questa sezione viene descritta la pipeline sperimentale implementata per analizzare e confrontare le diverse costruzioni di complessi simpliciali introdotte nel Capitolo 4. L'obiettivo è duplice: primo, valutare le prestazioni computazionali (tempo di esecuzione e memoria) di ciascun metodo; secondo, confrontare le proprietà topologiche catturate da ciascun complesso attraverso l'omologia persistente.

L'intero processo è stato automatizzato tramite script Python, sfruttando la libreria GUDHI per le costruzioni topologiche e i calcoli di persistenza.

La sperimentazione è stata strutturata in quattro fasi principali, a partire dalla ricostruzione del modello *Dragon* ottenuto da [3].

5.1 Estrazione dei Campioni

Sono stati estratti 7 campioni dal modello *Dragon*, utilizzando il software MeshLab. Tramite *clustered vertex sampling* sono stati selezionati dei gruppi di vertici in modo da mantenere la struttura topologica del modello originale. I campioni estratti hanno dimensioni variabili, da un minimo di 500 punti a un massimo di 4000 punti, come riportato in Tabella 1.

Campione	Numero di punti
1	500
2	1000
3	1501
4	2000
5	3002
6	3476
7	4000

Tabella 1: Dimensioni dei campioni estratti dal modello *Dragon*

5.2 Generazione dei Complessi

Per ognuno dei campioni sono stati costruiti i seguenti complessi simpliciali:

- Vietoris-Rips
- Čech
- Alpha
- Witness

Un aspetto cruciale della costruzione è stata la stima dei parametri di filtrazione, infatti ognuno dei complessi richiede un parametro `max_edge_length` o `max_alpha_square` che determina il valore massimo del parametro di filtrazione. A questo scopo è stato adottato un approccio adattivo basato sull'algoritmo del *k-nearest-neighbor*.

I complessi Čech e Alpha sono stati costruiti in due varianti ciascuno, una con il parametro di filtrazione calcolato come descritto sopra, e una con il parametro fissato a $+\infty$ (Delaunay Čech, Delaunay Alpha), in quanto nel secondo caso entrambi coincidono con il complesso di Delaunay ma con parametri di filtrazione diversi.

Il complesso Witness è stato invece costruito in tre varianti: debole (Witness), debole rilassato (Relaxed Witness) e forte rilassato (Strong Witness).

Possiamo vedere le diverse rappresentazioni dei complessi costruiti su uno stesso campione (in questo caso il più grande) nelle Figure 7 e 8 nell'Appendice.

5.3 Analisi delle Prestazioni

Durante la fase di costruzione, sono state misurate sistematicamente le prestazioni di ciascun algoritmo. In particolare, per ogni coppia (campione, tipo di complesso) sono stati registrati:

- **Tempo di elaborazione (s)**: il tempo totale impiegato per costruire il complesso simpliciale e calcolare la persistenza.
- **Memoria utilizzata (MB)**: la quantità di memoria RAM utilizzata durante la costruzione del complesso e il calcolo della persistenza.

Questi dati sono stati raccolti e presentati nelle tabelle in Figura 6, permettendo una valutazione oggettiva dell'efficienza di ciascuna costruzione.




Figura 6: Tabelle comparative delle prestazioni

È evidente dalle tabelle che il complesso di Vietoris-Rips è il più costoso in termini di tempo e memoria, specialmente per campioni di grandi dimensioni. Al contrario, i complessi Witness, soprattutto nella variante forte rilassata, si sono dimostrati molto più efficienti, il che li rende adatti all'analisi di dataset estesi.

5.4 Confronti

Il confronto qualitativo tra i complessi è stato effettuato analizzando i loro diagrammi di persistenza tramite la distanza bottleneck con il seguente processo:

- **Correzione dell'Infinito:** Le feature topologiche che "vivono per sempre" (con morte a $+\infty$) pongono un problema nel calcolo di distanze finite. Per ovviare a ciò, i punti all'infinito nei diagrammi di persistenza sono stati sostituiti con un valore finito, ma sufficientemente grande, derivato dal massimo valore di filtrazione osservato in tutti i complessi. Questo passaggio è fondamentale per rendere le distanze confrontabili.
- **Calcolo delle Matrici di Distanza:** Per ogni dimensione omologica (0, 1, 2), è stata calcolata una matrice contenente le distanze bottleneck tra ogni coppia di complessi.
- **Visualizzazione con Multidimensional Scaling (MDS):** Per interpretare visivamente le matrici di distanza, è stato utilizzato l'MDS. Questa tecnica proietta i complessi su un piano cartesiano in modo che la distanza euclidea tra i punti rispecchi la distanza bottleneck tra i complessi. Il risultato è un grafico in cui complessi topologicamente simili appaiono vicini, mentre quelli dissimili sono lontani. Questo viene fatto separatamente per ogni dimensione omologica, per capire quali feature sono catturate in modo più o meno simile dai diversi metodi.

I risultati di questi confronti sono riportati nella Figura 9 nell'Appendice, dove si può osservare il comportamento dei complessi al variare del numero di punti del campione. In particolare notiamo che in dimensione 0 la distanza tende a diminuire all'aumentare del numero dei punti, segno che tutti i complessi catturano in modo simile le componenti connesse del campione. In dimensione 1 e 2 invece la situazione è più variegata, con alcuni complessi che si avvicinano tra loro e altri che rimangono distanti.


Notiamo in particolare che i complessi Witness deboli non rilassati danno distanza 0 tra tutti in tutte le dimensioni, questo è dovuto al fatto che questo complesso ha pochissimi semplici a prescindere dal numero di vertici e quindi

i diagrammi di persistenza risultano molto simili con sole feature con morte a $+\infty$.

Osserviamo inoltre che i complessi di Delaunay costruiti in entrambi i modi (Delaunay Cech e Delaunay Alpha) sono quelli che più mostrano della convergenza in tutte le dimensioni.

5.5 Analisi della Convergenza

Infine, è stata studiata la stabilità e la convergenza di ciascun tipo di complesso all'aumentare della densità del campionamento. L'idea è che, man mano che la nuvola di punti diventa un campione migliore dello spazio sottostante, l'omologia calcolata dovrebbe stabilizzarsi. Questo è stato verificato calcolando la distanza bottleneck tra complessi dello stesso tipo, ma costruiti su campioni consecutivi (es. tra il campione da 500 punti e quello da 1000 punti). Ci si aspetta che un complesso robusto mostri una distanza bottleneck che tende a zero all'aumentare del numero di punti, indicando che la sua struttura topologica si sta stabilizzando. I risultati di questa analisi sono riportati nella seguente Figura.




Possiamo notare che in dimensione 0 e 2 c'è effettivamente una convergenza a 0, ma non si può dire lo stesso della dimensione 1, dove gli andamenti sembrano più irregolari. Vediamo sempre che il complesso Witness debole non rilassato dà distanza 0 tra tutti in tutte le dimensioni, per lo stesso motivo descritto sopra. Osserviamo infine che i complessi Delaunay Cech e Delaunay Alpha, così come Cech e Alpha, risultano sovrapposti, il che è coerente col fatto che siano costruzioni equivalenti del complesso di Delaunay.


Riferimenti bibliografici

- [1] D. COHEN-STEINER, H. EDELSBRUNNER, AND J. HARER, *Stability of persistence diagrams*, Discrete & Computational Geometry - DCG, 37 (2005), pp. 263–271.
- [2] H. EDELSBRUNNER AND J. HARER, *Computational Topology: An Introduction*, American Mathematical Society, 01 2010.
- [3] STANFORD UNIVERSITY COMPUTER GRAPHICS LABORATORY, *The stanford 3d scanning repository*. Available at <https://graphics.stanford.edu/data/3Dscanrep>. Accessed: 26 agosto 2025.
- [4] A. ZOMORODIAN AND G. CARLSSON, *Computing persistent homology*, Discrete and Computational Geometry, 33 (2005), pp. 249–274.


Appendice




Complesso Alpha



Complesso Čech




Complesso Delaunay Čech




Complesso Delaunay Alpha


Figura 7: Visualizzazioni di complessi costruiti sul campione da 4000 punti




Complesso Vietoris-Rips



Complesso Witness



Complesso Witness Rilassato



Complesso Witness Forte

Figura 8: Visualizzazioni di complessi costruiti sul campione da 4000 punti

Figura 9: Confronti delle distanze bottleneck tra lo stesso complesso calcolato su tutti i campioni

